

# Seminar pri predmetu računalniški sistemi 2022/23:

## Prepoznavanja aktivnosti in izračun porabljenih kalorij z mikrokrmilnikom ESP8266

Timotej Petrič, 63160264  
tp1859@student.uni-lj.si

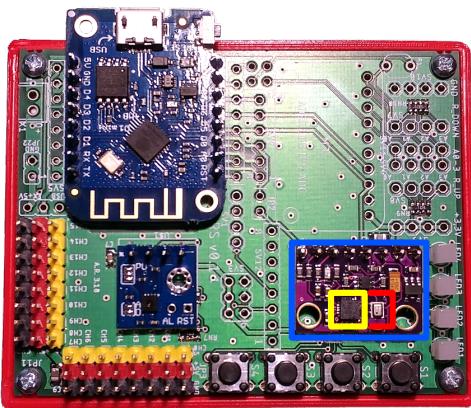
Aljaž Grdadolnik, 63160120  
ag5319@student.uni-lj.si

### I. UVOD

Telesna aktivnost in vadba imata pomembno vlogo pri ohranjanju zdravja in dobrega počutja. Svetovna zdravstvena organizacija (WHO) priporoča vsaj 150 minut zmerno intenzivne ali 75 minut intenzivne telesne aktivnosti na teden za odrasle. Za spremljanje in merjenje telesne aktivnosti se pogosto uporabljajo različne naprave in senzorji.

V tem članku predstavljamo uporabo mikrokrmilniškega modula ESP8266 in senzorja MPU9250 (na sliki 1) za zaznavanje telesne aktivnosti, šteje korakov ter izračun porabljenih kalorij. Opisujemo metodologijo, ki temelji na uporabi vgrajenega naključnega gozda (Random Forest) za prepoznavanje različnih aktivnosti, kot so hoja, tek, kolesarjenje in mirovanje. Z uporabo pospeškomетra MPU9250 zajemamo podatke o pospeških in kotnih hitrostih, ki jih nato obdelamo in klasificiramo s pomočjo modela na napravi. Nato izvedemo šteje korakov izračunamo porabljene kalorije.

Koda je prostost dostopna<sup>1</sup>.



Slika 1: Primer razvojne ploščice z mikrokrmilnikom ESP8266 - modra plošča levo gor - in MPU9250 - vijolčna ploščica desno spodaj.

### II. METODOLOGIJA

#### A. Omejeno okolje - vgrajene naprave - ESP8266

ESP8266 je majhen in zmogljiv mikrokrmilniški modul, ki omogoča povezavo z brezžičnim omrežjem Wi-Fi. Zaradi svoje nizke cene in kompaktnosti je primeren za uporabo v omejenih okoljih,

kot so vgrajene naprave. Modul ESP8266 ima omejeno količino pomnilnika in računske moči v primerjavi z računalniki, zato je treba pri načrtovanju upoštevati omejitve teh naprav.

#### B. Senzorji - MPU9250

Senzor MPU9250 združuje tri osi pospeškometra, tri osi žiroskopa in tri osi magnetometra v enem paketu. Ta kombinacija senzorjev omogoča zaznavanje gibanja v prostoru. S kombinacijo teh senzorjev lahko pridobimo podatke o telesni aktivnosti in gibanju.

Pred začetkom uporabe senzorjev pospeškometra in žiroskopa jih je treba kalibrirati. Za kalibracijo izvedemo povprečje 1000 zaporednih meritiv in nato od vsake nove meritve odštejemo to povprečje, da dobimo relativne meritve.

#### C. Zaznavanje aktivnosti - Model naključnega gozda

Za prepoznavanje aktivnosti uporabljamo model naključnega gozda (Random Forest). Ta model je primeren za uporabo na vgrajenih napravah, saj omogoča dober kompromis med hitrostjo in natančnostjo klasifikacije. Za učenje modela uporabimo podatke, ki smo jih zbrali med snemanjem vaj, kot so *hoja, tek in kolesarjenje*. Dodamo tudi *vzorce mirovanja*, da izboljšamo klasifikacijo. Podatke smo pošiljali iz naprave na domač računalnik preko protokola *MQTT*, uporabljali pa smo tudi spletni posrednik, ki nam je omogočal, da smo lahko napravo za zaznavanje le priključili na vir energije, ter pošiljali podatke na računalnik. Podatke pred učenjem tudi vizualiziramo, da se prepričamo o njihovi pravilnosti ter da oblikujemo rešitev za šteje korakov.

V posamezno okno za klasificiranje sva podala po 50 vzorcev meritiv s po 6 prostostimi stopnjami (degrees of freedom - DoF). Po 6 meritiv predstavlja x, y in z osi za senzor pospeška in kotnih hitrosti - žiroskop. Skupno imamo torej 300 vzorcev meritiv na klasifikacijo.

Vzorce meriva s 100 Hz, jih povprečiva z oknom dolžine 10 in tako dobiva 10 Hz uporabnih podatkov za klasifikacijo z modelom. Ker imamo po 50 meritiv naenkrat, to pomeni da naredimo eno klasifikacijo vsake 5 sekund.

Vsake 5 sekund uporabiva določene mejne vrednosti *threshold* in *away\_from\_previous\_peak* (opisane v podoglavlju II-D), da prestejeva število novih korakov, ki jih je uporabnik naredil v preteklih 5 sekundah.

#### D. Šteje korakov - Iskanje vrhov

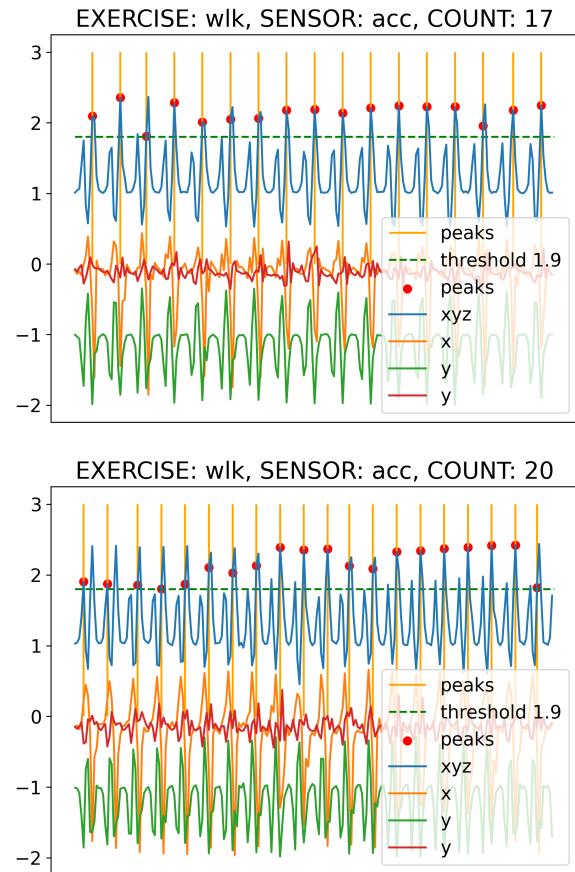
Za šteje korakov uporabljamo podatke iz pospeškometra, ki so že povprečeni z oknom, da je signal bolj gladek in da se izognemo šumu. Iz treh osi pospeškometa izračunamo intenziteto gibanja s pomočjo

<sup>1</sup><https://github.com/timopetric/har-calories-tracker>

formule  $\sqrt{x^2 + y^2 + z^2}$ . Nato nad tem signalom izvedemo iskanje vrhov, kjer vsak vrh predstavlja en korak. Za določitev, kdaj se nek vzorec intenzitete šteje kot vrh, in kako blizu so lahko posamezni vrhovi, določimo parametre praga (`threshold`) in oddaljenosti od prejšnjega vrha (`away_from_previous_peak`). Parametri so za različne tipe vaj določeni tako:

- hoja: `threshold` = 1.8 in `away_from_previous_peak` = 8,
- tek: `threshold` = 1.9 in `away_from_previous_peak` = 5 in
- kolo: `threshold` = 1.2 in `away_from_previous_peak` = 7.

Primeri podatkov pospeškometra nad katerimi izvajamo funkcijo štetja vrhov za različne tipe vaj so prikazani na slikah 2, 3 in 4.



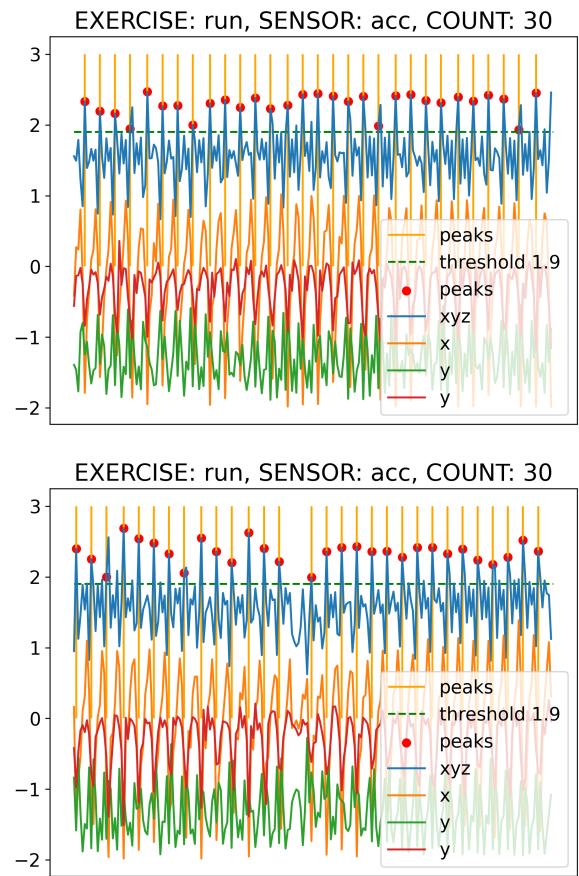
Slika 2: Šteti korakov. Primer dveh izsekov posnetka vaje *hoja* (*wlk*). Z zeleno vodoravno črtko je označena mejna vrednost. Rdeče pike in oranžne vodoravne črte predstavljajo zaznan korak. Iz prikazanih podatkov vidimo, da so koraki šteti pravilno.

#### E. Aplikacija na strežniku

Za preizkus delovanja naše aplikacije smo naredili lokalni spletni strežnik z uporabo knjižnice *ESP8266WebServer* ter *ESP8266WiFi*. Poleg tega smo naredili tudi enostaven zaledni del, napisan v jeziku Python, kjer smo za bazo uporabili preprosto shranjevanje v datoteke CSV. Za komunikacijo med steznikom in zalednim delom, ki je bil zagnan na domačem računalniku, smo uporabili knjižnico *PubSubClient*, ki deluje na protokolu *MQTT*.

Za prenos podatkov smo enako kot pri zajemanju podatkov, ki smo jih opisali v pod sekcijsi Zaznavanje aktivnosti - Model naključnega gozda, uporabili spletni posrednik.

Spletna aplikacija omogoča pregled trenutne aktivnosti, kjer lahko vidimo, koliko korakov, tekaških korakov ali zamahov s pedali smo



Slika 3: Šteti korakov. Primer dveh izsekov posnetka vaje *tek* (*run*). Z zeleno vodoravno črtko je označena mejna vrednost. Rdeče pike in oranžne vodoravne črte predstavljajo zaznan korak. Iz prikazanih podatkov vidimo, da so koraki šteti pravilno in da je metoda dovolj robustna.

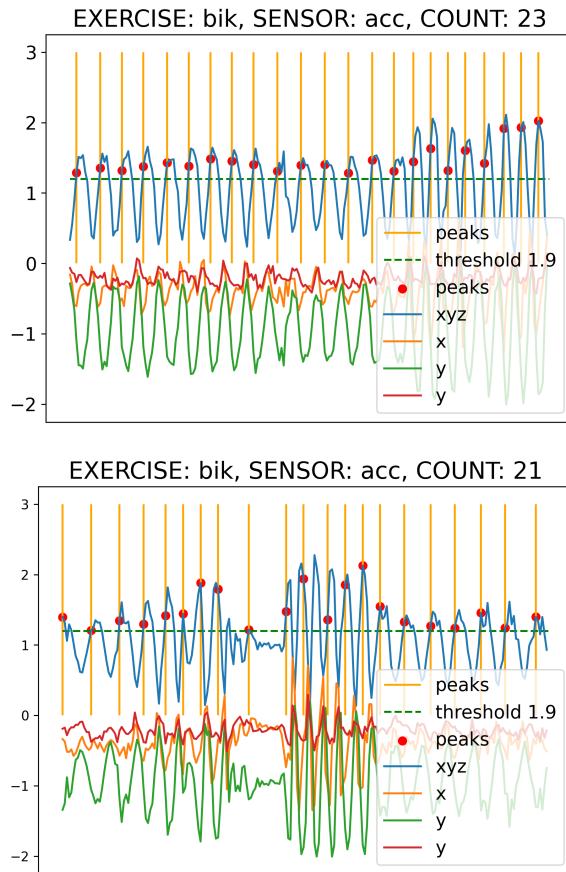
naredili. Aktivnost lahko ustavimo, nakar se tudi pošljejo podatki na bazo in kasneje pričnemo z novo aktivnostjo, kateri podatki se bodo na koncu ravno tako zapisali v bazo za isti dan.

Na prvi strani imamo tudi iskalnik po datumih, kamor vpišemo željeni datum in dobimo podatke o aktivnostih tisti dan ter število kalorij, ki smo jih porabili v celiem dnevu. Število kalorij smo izračunali na sledeč način: predvidevali smo povprečno višino moškega, ki je v Sloveniji približno 180 centimetrov[1], ter težo 75 kilogramov. Izračunali smo dolžino koraka, ki smo jo dobili po enačbi:  $korak = visina * 0.414$  za hojo in to pomnoženo za tek, prehojeno oziroma pretečeno dolžino:  $dolzina = korak * \#korakov$ , čas:  $cas = dolzina / hitrost$ , kjer je bila hitrost privzetna 1.34 m/s za hojo in 4 m/s za tek. Vse te podatke smo nato združili v enačbo za število porabljenih kalorij:  $\#korakov = as * MET * 3.5 * teza / (200 * 60)$ [2], kjer je *MET*(angl. Metabolic Equivalent of Task).

Pogledamo lahko tudi podatke za aktivnosti prejšnjega dneva, kjer pa imamo tudi prikazovalnik razlike med današnjimi aktivnostmi ter včerajšnjimi, kar nam lahko služi kot vzpodbuda za rekreacijo.

### III. REZULTATI

Končno rešitev smo testirali z izvedbo različnih vaj. Rezultati model kažejo da model naključnega gozda zelo dobro napoveduje katera vaja se trenutno izvaja. Po narejenih 100 korakih hoje, kratkem premoru, 100 vrtljajih pedal na kolesu in nato še 100 korakih teka je



Slika 4: Štetje vrtljajev pedal na kolesu. Primer dveh izsekov posnetka vaje *kolo* (*bik*). Z zeleno vodoravno črtkano črto je označena mejna vrednost. Rdeče pike in oranžne vodoravne črte predstavljajo zaznan vrtljaj. Iz prikazanih podatkov vidimo, da so vrtljaji šteti pravilno in da je metoda dovolj robustna.

stran kazala 98 korakov za hojo, 88 vrtljajev pedal in 84 korakov za tek. Rešitev torej dobro zaznava in šteje izvedbe različnih vaj.

Za izboljšanje bi lahko implementirali boljši algoritem za štetje in zbrali več posnetkov vaj različnih ljudi, s čimer bi izboljšali napovedno vrednost novo naučenega modela naključnega gozda.

#### IV. ZAKLJUČEK

V tem članku smo predstavili implementacijo sistema za zaznavanje telesne aktivnosti, štetje korakov in izračun porabljenih kalorij s pomočjo mikrokrmlniškega modula ESP8266 in senzorja MPU9250. Z uporabo modela naključnega gozda smo uspešno prepoznali različne aktivnosti, kot so hoja, tek, kolesarjenje in mirovanje. Poleg tega smo izvedli tudi štetje korakov na podlagi pospeškov in izračunali porabljenе kalorije.

Implementirali smo tudi spletni strežnik, ki omogoča shranjevanje podatkov v bazo in prikazovanje trenutne aktivnosti ter primerjavo z zgodovinskimi podatki. Ta funkcionalnost omogoča uporabnikom, da pregledujejo svoje vadbe in spremljajo napredek ter imajo s tem motivacijo za rekreiranje in bolj zdravo življenje.

Implementiran sistem predstavlja enostavno in učinkovit način za beleženje vadb. V prihodnosti bi lahko sistem nadgradili z dodatnimi senzorji in funkcionalnostmi ter ga prilagodili različnim potrebam in uporabniškim scenarijem. Dodali bi lahko tudi majhno baterijo in namesto uporabe celotne razvijalne ploščice iz slike 1 uporabili le

nujno potrebne komponente, kar bi zmanjšalo težo in ceno končnega produkta.

#### LITERATURA

- [1] G. Starc and J. Strel, "Is there a rationale for establishing slovenian body mass index references of school-aged children and adolescents?" *Anthropological Notebooks*, vol. 17, no. 3, 2011.
- [2] A. G. Brooks, S. M. Gunn, R. T. Withers, C. J. Gore, and J. L. Plummer, "Predicting walking mets and energy expenditure from speed or accelerometry." *Medicine and Science in Sports and Exercise*, vol. 37, no. 7, pp. 1216–1223, 2005.